

个人课题 (选题 3) 汇报

姓名：魏知原

学号：2300012875

1 任务 1: MDP 形式化与环境分析

本项目使用 MiniGrid-Dynamic-Obstacles 系列环境，并按要求使用 SymbolicObsWrapper 对环境进行包装。包装后，观测仍然是字典形式，主要字段包括 `image`、`direction` 和 `mission`。其中 `image` 不再是原始 RGB 局部视野，而是完整网格的符号化表示，形状为

$$(N, N, 3),$$

其中 N 是网格边长。每个格子的三元组可理解为

$$(x, y, object_id),$$

即该格子的横坐标、纵坐标和对象编号。包装器会将智能体所在格子的对象编号标记为 `agent`，因此该观测可以直接反映完整网格中墙、空地、目标、移动障碍物和智能体的位置。环境任务文本固定为 “get to the green goal square”，因此在本项目的 MDP 分析中，`mission` 不作为额外变化状态处理。

1.1 状态空间 S

从马尔可夫性的角度，一个足够描述环境动态的紧凑状态可以写成

$$s = (x_a, y_a, d_a, p_1, p_2, \dots, p_k),$$

其中 (x_a, y_a) 是智能体位置， $d_a \in \{0, 1, 2, 3\}$ 是智能体朝向， p_i 是第 i 个动态障碍物的位置， k 是障碍物数量。边界墙的位置固定，目标格固定在右下角内侧 $(N-2, N-2)$ ，因此不需要作为变化变量计入状态。

为了估计理论状态空间大小，令

$$M = (N-2)^2 - 1$$

表示去除边界墙并排除目标格之后，可由智能体或障碍物占据的内部非目标格数量。若把障碍物视为同质对象且不允许多个对象占据同一格，则非终止状态空间大小的近似上界为

$$|S| \approx 4 \cdot M \cdot \binom{M-1}{k}.$$

这里的 4 来自智能体的四个朝向， M 是智能体位置数， $\binom{M-1}{k}$ 是在智能体所在格之外选择 k 个障碍物位置的组合数。

环境规模	障碍物数量 k	M	估计状态数
5x5	2	8	672
8x8	4	35	6,492,640
16x16	8	195	33,533,784,962,552,160

MiniGrid-Dynamic-Obstacles-Random-5x5-v0 与普通 5x5 环境的网格规模和障碍物数量相同，因此理论状态空间规模相同；区别主要体现在初始状态分布上，随机版本会随机化智能体初始位置和方向。移动障碍物显著扩大了状态空间：如果没有障碍物，状态主要由智能体位置和朝向组成；加入多个动态障碍物后，状态还必须包含障碍物的位置组合，状态数随网格规模和障碍物数量呈组合式增长。这正是表格型 Q-Learning 在大网格中面临维度灾难的根本原因。

1.2 动作空间 A

Dynamic-Obstacles 环境将动作空间限制为三个离散动作：

$$A = \{\text{left}, \text{right}, \text{forward}\}.$$

对应编号为：

编号	动作	含义
0	left	向左旋转
1	right	向右旋转
2	forward	向当前朝向前进一格

MiniGrid 通用动作集合中还包含 `pickup`、`drop`、`toggle` 和 `done`，但在本环境中这些动作不可用。

1.3 奖励函数 R

该环境奖励较稀疏。普通移动或转向通常得到 0 奖励；当智能体成功到达目标格时，回合终止并获得带时间衰减的正奖励：

$$R_{\text{success}} = 1 - 0.9 \cdot \frac{\text{step_count}}{\text{max_steps}}.$$

因此越早到达目标，奖励越高。若智能体尝试向前进入动态障碍物或墙所在格，会得到 -1 惩罚并终止回合。若达到最大步数仍未成功，则回合被截断，失败奖励为 0。整体来看，奖励信号主要出现在成功、碰撞和超时等事件上，因此属于稀疏奖励问题。

1.4 转移概率 P

在给当前状态和动作时，智能体自身的转向和前进一步规则是确定性的；例如 `left` 和 `right` 只改变朝向，`forward` 尝试沿当前朝向移动一格。但是整个环境转移并非确定性，因为每一步中动态障碍物会在其当前位置附近的 3×3 区域内重新采样可用位置。该采样依赖环境随机数，并且可能受到墙、目标、智能体和其他障碍物占位情况的限制。因此总体转移概率应写作

$$P(s' | s, a),$$

而不是确定性映射 $s' = f(s, a)$ 。

对于普通 5x5、8x8 和 16x16 版本，初始位置通常是固定的，但回合内部仍然因为动态障碍物移动而具有随机性；对于 `Random-5x5-v0`，初始状态分布本身也具有随机性。这意味着 PPO 等函

数逼近方法不仅要学习避障策略，还需要对不同初始状态具有一定泛化能力，而表格型 Q-Learning 则需要为大量离散状态分别估计动作价值。

1.5 小结

任务一的分析说明，MiniGrid-Dynamic-Obstacles 可以形式化为一个有限但规模快速膨胀的离散 MDP。小规模环境中表格型 Q-Learning 尚有可能覆盖较多状态，但当环境扩展到 16x16 且包含 8 个动态障碍物时，理论状态空间已经达到约 3.35×10^{16} 量级。该结果预示了后续实验中表格方法可能遭遇严重样本效率和存储效率问题，也为比较 PPO 的函数逼近和泛化能力提供了依据。

2 任务 2：算法实现、超参数与单次实验总结

本项目实现并比较了表格型 Q-Learning 与 PPO-Clip。二者都使用 SymbolicObsWrapper 后的符号观测，但状态利用方式不同。Q-Learning 将完整 object layer 与朝向拼成离散 key；PPO 使用一个小型 CNN actor-critic，对 $3 \times N \times N$ 的符号图像通道进行卷积编码，并将朝向 one-hot 后拼接到特征中。

2.1 超参数设置

Q-Learning 使用学习率 $\alpha = 0.2$ ，折扣因子 $\gamma = 0.99$ ，epsilon-greedy 探索从 1.0 线性衰减到 0.05，衰减步数为 40,000。Q 表初始值均为 0。5x5 与 Random-5x5 训练 50,000 steps；8x8 的多 seed 实验训练 100,000 steps；16x16 的最新多 seed 实验训练 130,000 steps，另有单 seed 200,000 steps 的补充观察。

PPO-Clip 使用学习率 3×10^{-4} ， $\gamma = 0.99$ ，GAE 参数 $\lambda = 0.95$ ，clip 系数 0.2，value loss 系数 0.5，entropy 系数默认 0.01。每次 rollout 长度为 1024，minibatch size 为 256，每个 rollout 更新 4 个 epoch。CNN 通道数设为 16，隐藏层宽度设为 64，以便调试和控制计算量。PPO 使用原始环境奖励，未加入额外 reward shaping；我也尝试过将 entropy 系数调大到 0.05、0.1、0.3，但并没有解决成功率塌缩的问题。

2.2 单次实验现象

在 seed 23 的单次实验中，Q-Learning 在两个 5x5 环境中表现良好：普通 5x5 最后 100 回合成功率达到 91.00%，Random-5x5 最后 100 回合成功率达到 99.00%。对应的 Q-table size 分别约为 646 和 672，说明小环境中的可访问状态基本被覆盖。

但在大棋盘上，Q-Learning 失败明显。8x8 在 200,000 steps 下最终 Q-table size 达到 160,557，最后 100 回合成功率为 0；16x16 的 Q-table size 达到 199,792，且未出现成功回合。这说明表格方法在大棋盘上持续遇到新状态，无法充分复用已有估计。

PPO-Clip 的主要现象是：优化指标可以变得稳定，但任务成功率仍然接近 0。debug log 显示，PPO 初期会尝试 forward，但很快学到减少前进动作以避免碰撞；后期策略多表现为左右转并拖到 timeout。也就是说，PPO 并不是完全没有学习，而是陷入了一个局部最优：在稀疏正奖励和碰撞负反馈下，原地左右转比主动前进更容易获得“看起来不太差”的回报。将 entropy 系数调大后，探索稍有变化，但仍未形成稳定到达目标的策略。




图 1: PPO-Clip 在 5x5 上容易学到避免碰撞但不到达目标的 timeout policy。




图 2: PPO entropy=0.05




图 3: PPO entropy=0.1




图 4: PPO entropy=0.3

3 任务 3：多随机种子下的比较分析

任务三中，我使用随机种子 {1, 23, 31, 42, 97} 进行重复实验，并对回合回报曲线在相同 timestep 网格上取平均。5x5 与 Random-5x5 使用 50,000 steps，8x8 使用 100,000 steps，16x16 使用最新的 130,000 steps 结果。图中曲线为 5 个随机种子的均值，并绘制标准差阴影。

3.1 学习曲线




图 5: 5x5 平均学习曲线




图 6: Random-5x5 平均学习曲线




图 7: 8x8 平均学习曲线




图 8: 16x16 平均学习曲线

3.2 定量结果

算法	环境	steps	全程成功率	最后 100 成功率	最后 100 平均回报
Q-Learning	5x5	50,000	29.10%	89.60%	0.684
Q-Learning	Random-5x5	50,000	56.50%	96.20%	0.870
Q-Learning	8x8	100,000	0.06%	0.00%	-0.806
Q-Learning	16x16	130,000	0.00%	0.00%	-0.972
PPO-Clip	5x5	50,000	0.38%	0.00%	-0.032
PPO-Clip	Random-5x5	50,000	7.11%	0.20%	-0.010
PPO-Clip	8x8	100,000	0.05%	0.00%	-0.016
PPO-Clip	16x16	130,000	0.00%	0.00%	-0.076

3.3 维度灾难

当环境从 5x5 扩展到 16x16 时，表格型 Q-Learning 的表现迅速恶化。5x5 中平均最终 Q-table size 约为 647，Random-5x5 为 672，与理论状态规模同量级，因此每个状态可以被多次访问并更新；而 8x8 训练 100,000 steps 后，平均 Q-table size 已经达到约 90,116。16x16 在最新的 130,000 steps 实验中，平均 Q-table size 进一步达到约 129,848，几乎等于环境交互步数。这意味着大棋盘 中 Q-Learning 仍在不断发现新状态，无法形成稳定价值估计。

从成功率看，Q-Learning 在 5x5 最后 100 回合平均成功率为 89.60%，Random-5x5 为 96.20%；但在 8x8 和 16x16 的最后 100 回合成功率均为 0。即使将 16x16 的训练步数增加到 130,000，五个随机种子仍然没有任何成功回合，Q-table 只是继续增长。这正体现了维度灾难：状态空间的组合式增长使表格方法的样本效率急剧下降。

3.4 泛化能力

Random-5x5-v0 随机化了智能体初始位置和方向。Q-Learning 在该环境中仍表现很好，最后 100 回合平均成功率达到 96.20%。原因是 Random-5x5 的状态空间仍然很小，Q-table 最终覆盖到 672 个状态，表格方法通过枚举状态也能处理随机初始分布。

PPO 理论上具有函数逼近带来的泛化能力，但本实验中的 PPO-Clip 并没有充分体现这一优势。在 Random-5x5 中，PPO 全程平均成功率为 7.11%，高于普通 5x5 的 0.38%，说明随机初始位置确实带来了更多成功样本和更丰富探索；但最后 100 回合成功率仍只有 0.20%。这表明 PPO 并未稳定学到目标导向策略，而是倾向于学习避免碰撞、拖到超时的保守策略。尤其是在动作分布收敛后，策略常表现为连续选择 left/right，通过改变朝向来消耗步数，而不是利用已有视觉特征规划到达 goal。

3.5 计算效率与样本效率

在小规模环境中，Q-Learning 的样本效率最高。5x5 中它在 50,000 steps 内达到接近 90% 的末尾成功率；Random-5x5 中甚至接近 96%。PPO 在同样步数下虽然可以把平均回报从频繁碰撞的负值提高到接近 0，但没有转化为成功率提升，因此从任务成功角度看样本效率较低。

在大规模环境中，两种算法都没有解决任务，但失败方式不同。Q-Learning 的失败主要来自状态空间爆炸，训练越久 Q-table 越大；PPO 的失败主要来自稀疏奖励下的局部最优，它能学会减少碰撞和延长回合，但不一定到达目标。更具体地说，PPO 学到的是“少做危险的 forward，多做左右转”的策略；这会提高平均回报、降低碰撞频率，却牺牲了真正的成功率。PPO 在 8x8 和 16x16 在 130,000 steps 后最后 100 回合平均回报约为 -0.076，最后 100 回合平均长度约为 982 steps，看似优于 Q-Learning 的大负回报，但这主要代表 timeout，而不是成功完成任务。

3.6 总结

综合来看，表格型 Q-Learning 在小状态空间中简单、高效、稳定，但随环境规模扩大迅速遭遇维度灾难。PPO-Clip 具备函数逼近能力，并在随机初始位置下能获得更多早期成功样本，但在本实验的稀疏奖励 Dynamic-Obstacles 任务中，最终未能形成稳定成功策略。后续若要提升 PPO，可能需要课程学习、并行环境采样、更充分的训练预算，或引入合理的辅助奖励；而若坚持使用表格方法，则必须设计远比完整棋盘 object layer 更紧凑的状态抽象。